RailFuse ContextStore

以更少的内存搬运，交付可验证的完整 KV 对象

面向版本化 KV Cache 对象的故障原子多轨读取引擎

单个推理 Worker 使用多条 RDMA 路径读取既有条带对象，在私有暂存中完成既定完整性与身份检查后统一发布；异步错误发生后，先结束相关 DMA 所有权，再允许内存复用。

怎样分配路径	何时发布结果	何时回收内存
Placement 与版本约束 按字节规划和资源预算	私有有序暂存 完整性、版本和取消检查	QP 退休与 CQ 排空 显式重连和句柄生命周期

三组互补证据

开销：固定调度的直接暂存对照。
版本：读取期间的 Generation 切换见证。
生命周期：旧库真实污染负对照与修复版复用、重连验证。

作品基于 DaoCloud ContextStore；沿用其服务、协议和磁盘布局，新增客户端路径规划、私有暂存与发布控制，并强化跨语言接口生命周期。

核心安全源码：39ce2d50fcee00405758f1e2c4f7bd389baccf1c

提交仓库与最新材料入口

01 一次对象读取，三个不同的完成条件

在共享 KV Cache 场景中，推理 Worker 从存储读取一个对象。对象由多个条带组成，读取期间可能被覆盖更新；一条 RDMA 路径可能失败，晚到写入也可能越过 API 的错误返回。

失败原因	为什么简单并行不够	对应设计
对象与路径的身份约束	字节相加完整，也可能混入已经失效的对象身份	复用 Placement 与条带归属，传输后复查版本和布局
隔离部分结果的开销	各轨 packed 缓冲区再组装，会增加完整对象的内存搬运	符合条件时，各轨直接写入同一私有有序暂存的不同区域
请求与 DMA 的结束时刻不同	错误已返回，QP 或旧完成事件仍可能影响后续复用	返回前退休 QP、排空 CQ，建立明确的重连和释放边界

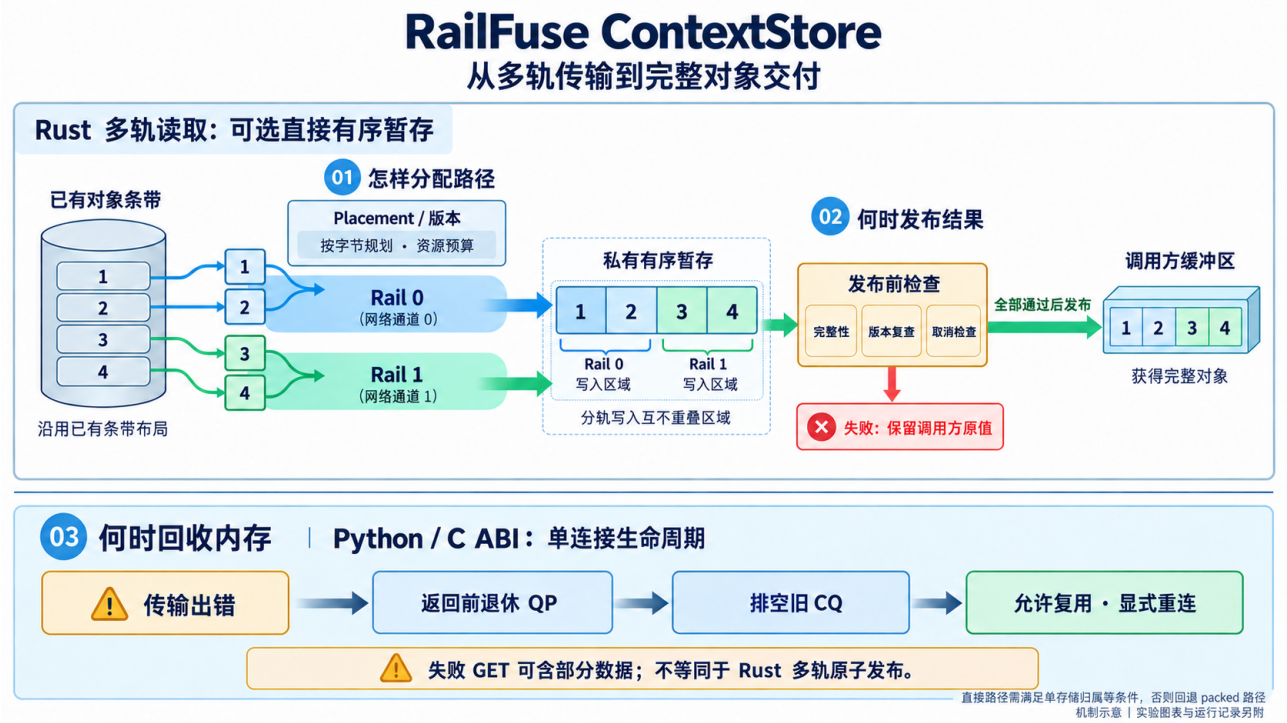
统一管理的是“ 这次对象读取的交付条件 ”

路径计划规定读取哪些字节；发布门规定调用方何时能接受结果；退休与回收规定失败后哪些资源可以重新使用。三个决策形成一个可解释、可验证的对象读取流程。

应用价值与测量范围

已有证据覆盖真实 Verbs 执行、软件数据路径开销和异常处理。实际业务中的首 token 时延、端到端推理吞吐与成本，仍需结合推理框架、访问局部性和部署硬件测量。

02 总体架构：沿用条带，明确发布与回收



Rust 多轨读取：可选直接有序暂存

根据 Placement、监听端点与本地设备规划条带。直接路径在单存储归属等条件满足时启用，各 Rail 借用互不重叠的私有有序区域；否则回退 packed 路径。所有必要任务结束并通过检查后，再向调用方发布。

Python / C ABI：单连接生命周期

Python 外部缓冲区接口单独采用串行生命周期、错误前退休 QP 和重连前排空 CQ。失败 GET 可以留下已经写入的部分数据；它不自动获得 Rust 多轨读取的原子发布语义。

图为机制示意。两条接口的发布语义分别实现与验证。实验图表来自原始审计数据，运行画面来自实际执行记录。

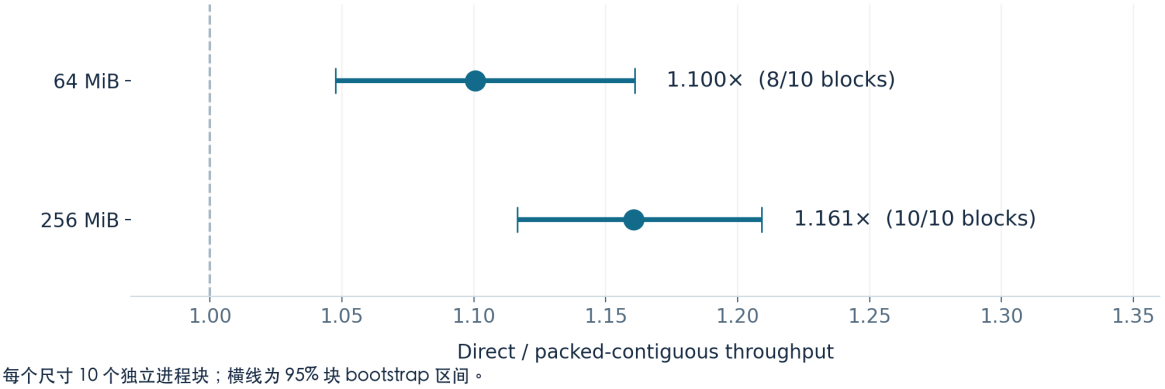
03 机制与收益：降低安全暂存的组装开销

反例：安全地隔离部分结果，却为完整对象多做一次组装。

直接有序暂存把符合条件的条带分配成连续区域，让各轨写入一个请求私有向量的互不重叠部分。发布前的校验和、身份复查及取消门保留；避免 packed 到对象顺序的组装步骤。

固定调度后，直接有序暂存仍有收益

2026-10-09 归档实验 · 双 RXE / KVM · 相同条带计划



每个尺寸 10 个独立进程块；横线为 95% 块 bootstrap 区间。

两个尺寸的服务端源条件不同，分别作尺寸内比较；不作为物理双 HCA 聚合结论。

对象 / 模式	客户端 CPU ms / 完成读*	客户端峰值 RSS MiB
64 MiB，packed-contiguous → Direct	123.9 → 76.5	206.3 → 142.5
256 MiB，packed-contiguous → Direct	433.6 → 259.4	782.5 → 526.6

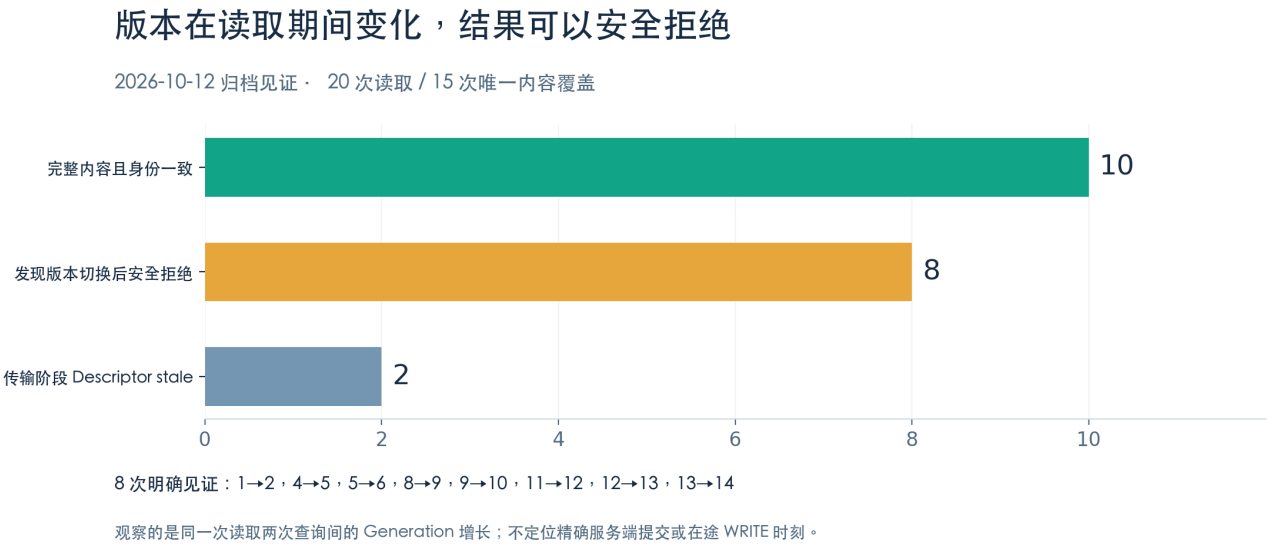
比较固定相同的条带计划；每个尺寸 10 个独立进程块，每模式 1 次预热与 5 次测量。吞吐比按块内延迟中位数形成配对比值；CPU* 含预热和进程设置的摊销，和延迟统计口径不同。

本页为 2026-10-09 归档实验。两档尺寸使用不同服务端源条件，分别作尺寸内比较；相同注册 / 在途载荷规模下，CPU 与 RSS 下降。净实现效果包含分配、注册与清理差异，不是纯 memcpy 耗时估计。[E1]

04 版本见证：读取期间变化就安全拒绝

反例：传输开始时有效的对象，在发布之前已被覆盖。

在“ 初次查询 → 私有暂存传输 → 再次查询 ”的顺序中，比较对象、Generation、布局及 Placement 身份。身份变化时拒绝发布，调用方缓冲区保持原值。

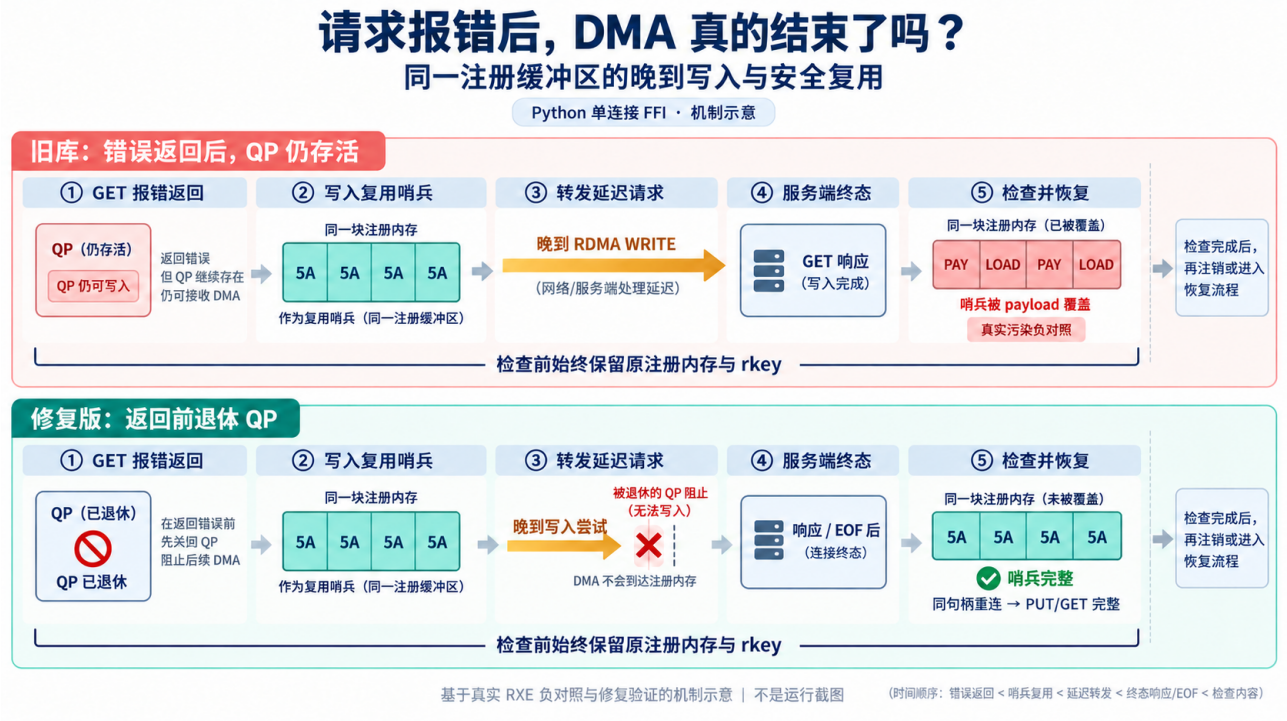


证据如何解释

2026-10-12 的归档实验使用一个顺序读客户端和一个覆盖写客户端。20 次读取中，10 次返回完整且身份一致的内容，10 次安全拒绝；其中 8 次明确观察到同一次读取两次查询间的 Generation 增长，另 2 次在传输阶段发现描述符失效。

这 8 次见证支持元数据版本切换发生在两次观察之间；不定位精确服务端提交时间，也不证明提交与 RDMA WRITE 在途时刻相交。源码快照、二进制与独立审计均保存。[E2]

05 真实反例：错误返回后，内存仍会被写入



本次重新执行的演示结果

观察项	旧库负对照	修复版
同一注册内存复用后的内容	精确变成服务端 payload	0x5A 哨兵保持完整
内容哈希核对	实际污染哈希 = 预期 payload 哈希	实际哨兵哈希 = 预期哨兵哈希
错误后同一 native handle 恢复	只记录污染，不作恢复主张	显式重连后 PUT / GET 全内容一致

不可提前省略的观察顺序

错误返回 → 写入复用哨兵 → 转发延迟请求 → 服务端响应 / EOF → 检查内容 → 注销或进入恢复。原分配和 rkey 保留到检查结束，避免用换缓冲区或提前检查制造假阳性。

2026-10-16 V2 新采集：1 MiB、单条 RXE 路径的旧 / 新库演示。更完整的两条链路、1 / 8 MiB、错误标签 / 超时矩阵另存于 10 月 16 日冻结收据。[E3][E4]

06 工程闭环：旧事件不进入下一次请求

PUT 的另一条风险：旧 CQ 完成事件被下一次请求误用。

受控观察器暂时令 CQ 轮询返回 0；QP 退休后读取真实 provider WC，验证旧完成事件在错误返回前被消费。随后同一句柄、同一注册内存重连，完成三轮实际 PUT / GET，并逐字节校验。

证据层	冻结验收结果	本次 V2 演示
Python / 原生生命周期	165 passed、11 skipped；native 13 / 13；receipt 6 / 6	沿用冻结的回归证据，核心实现未改
真实 RXE GET	修复版 8 / 8；旧库精确污染 2 / 2	重新执行旧 / 新库各 1 次，结果符合判据
真实 RXE PUT / CQ	两条链路各 1 次；每条三轮恢复	单条链路重录，真实旧 WC 排空与三轮恢复通过
当前 Rust 使用流程	64 MiB 完整读与每 Rail 字节守恒	重新写入并核对内容，单 / 双轨哈希一致

独立复核发现并修正的两个边界

描述符与字符串：拒绝 ctypes 整数收窄和 NUL 别名；字段只读取一次，验证并传递同一快照。
关闭与中断：原生 free 前先从 Python 对象移走句柄，避免释放完成后遇到中断而重复释放。

V2 保留带时间的终端事件流、每个探针 stdout / exit / JSON / events，以及执行前后库和脚本哈希。CQ 是受控轮询抑制；WC 内容来自真实 provider。[E3][E4]

07 应用、部署与演示入口

适用场景	可使用能力	需要结合场景测量
共享 KV Cache / 长上下文复用	版本化对象，多路径读取与完整发布	推理框架接入、命中模式和端到端收益
暴露多条网络路径的存储节点	已有布局上的路由匹配和按字节规划	物理双 HCA、多 NVMe 与瓶颈归因
Python / pinned buffer 调用方	注册、GET / PUT、错误后重连和生命周期边界	原始视图、外部内存的调用方责任

演示时按四个动作推进

1. 展示架构图，用一句话解释三项决策。
2. 执行 read：写入 64 MiB，再比较单轨与双轨的对象哈希、条带分配和每轨字节。
3. 执行 late：观察旧库污染和修复版哨兵，再展示同一句柄重连结果。
4. 执行 put：指出旧 WC 在错误返回前排空，并核对三轮恢复。

配套文件

四分半有声演示
照着操作与讲解的演示提词卡
运行脚本与原始终端记录

环境前提：Linux、libibverbs/provider、Rust 与 Python（项目要求 3.10+），服务端 Redis、存储目录和 RXE listener 已配置。项目构建入口为 make build；详细操作见提词卡。

08 复现、贡献归属与交付范围

完整源码与开源归属

RailFuse 提交仓库
本轮核心安全修复固定提交

作品基于 Apache-2.0 的 DaoCloud ContextStore，沿用其服务、协议、存储条带、元数据和依赖能力。新增客户端机制与研究分支改动按代码历史归属；独立 PR 的审阅、官方 CI 和合并状态单独报告。

证据索引

[E1] 2026-10-09 固定调度开销对照：实验说明与原始审计

[E2] 2026-10-12 Generation 切换：见证说明与收据

[E3] 2026-10-16 冻结 FFI / RXE 验收：独立复核、完整矩阵与归因

[E4] 2026-10-16 V2 新终端录制：带时间的事件流与逐项原始输出

范围与下一项实证

本次数据面是同一宿主机上的两台 KVM、两条 RXE 网络和虚拟盘。支持真实 Verbs 执行、所测异常场景与软件开销对照；物理双 HCA 聚合、真实 provider 故障、所有交错的形式化证明及端到端推理收益仍需专项验证。

画面与时间

机制图由图像生成工具制作并校对；数据图从真实审计 JSON 绘制。视频按“ 新终端录制 + 机制图 + 已注明日期的历史证据 ”剪辑配音；完整未剪辑终端事件流另附。现场本人讲解时长需排练确认。

材料准备、仓库推送、正式邮件发送和组委会回执分别留存。按用户提供的通知，作品材料截止 2026-10-16 24:00；收件邮箱 oscc@oschina.cn。